راهنمای شخصی — تیم Phoenix

به‌روز ماندن در هوش مصنوعی: مفاهیم، اعداد و منابع

این راهنما کمک می‌کند مفاهیم اصلی هوش مصنوعی را بفهمید، صفحه یک مدل در Hugging Face و جدول رتبه‌بندی‌ها را درست بخوانید، معنی اختصارها و اعداد را بدانید و هر هفته با یک روال ساده به‌روز بمانید.

هدف	خودتان بتوانید یک مدل تازه را بخوانید، بسنجید و بگویید به درد Phoenix می‌خورد یا نه.
مخاطب	مدیر محصول فنی و هر کسی در تیم که می‌خواهد از خبرها عقب نماند
تمرکز ویژه	هوش مصنوعی صوتی (گفتار به متن، متن به گفتار، تشخیص نوبت) — چون Phoenix یک دستیار صوتی فارسی است
مبنا	مستندات Hugging Face، مقاله‌ها و وب‌سایت جدول‌های رتبه‌بندی (بازدید مهر ۱۴۰۵)
تاریخ	۱۵ مهر ۱۴۰۵

راهنمای خواندن

این سند یازده فصل دارد. لازم نیست همه را یک‌جا بخوانید. اگر عجله دارید، این چهار فصل را اول بخوانید:

۱. **خواندن Hugging Face** — تا صفحه هر مدل را بفهمید.
۲. **فرهنگ اختصارات** — هر وقت به حرفی مثل SFT یا RTFx رسیدید، اینجا را باز کنید.
۳. **فهرست مدل‌های معروف** — Llama، Gemma، Qwen و بقیه؛ هر کدام برای چه کاری.
۴. **روال هفتگی** — تا یادگیری یک عادت شود، نه یک پروژه.

اصطلاح‌ها به انگلیسی هم آمده‌اند، چون در سایت‌ها و مقاله‌ها همان شکل انگلیسی را می‌بینید. هر اصطلاح اولین بار که می‌آید توضیح داده می‌شود.

یک هشدار: این حوزه هر ماه عوض می‌شود. عددهای جدول‌ها و رتبه مدل‌ها را عمداً ننوشته‌ایم، چون زود کهنه می‌شوند. فصل «فهرست مدل‌های معروف» فقط **خانواده‌ها و کاربردشان** را می‌گوید، نه نسخه برتر امروز. به جای عدد، یاد می‌گیریم **چطور** جدول‌ها را بخوانیم. مفهوم‌ها و روش‌ها سال‌ها معتبر می‌مانند.

مسیر ۳۰ / ۶۰ / ۹۰ روزه

بازه	هدف	کار عملی
روز ۱ تا ۳۰	مفاهیم پایه و زبان مشترک. بدانید توکن، پنجره متن، تنظیم دقیق و RAG چیست.	فصل «مفاهیم پایه»، «موضوع‌های تکمیلی» و «فهرست مدل‌های معروف». فصل‌های اول دوره LLM در Hugging Face. هر روز ۱۵ دقیقه روال روزانه.
روز ۳۱ تا ۶۰	خواندن مدل و جدول. صفحه هر مدل را بفهمید و عددها را مقایسه کنید.	فصل ۳ و ۵. تمرین ۱ و ۲ از فصل آخر. یک مدل کوچک را روی لپ‌تاپ اجرا کنید.
روز ۶۱ تا ۹۰	صدا و ارزیابی خودتان. بتوانید دو مدل گفتار به متن را روی صدای فارسی خودمان مقایسه کنید.	فصل ۶. دوره صوت Hugging Face. تمرین ۳. یک گزارش یک‌صفحه‌ای برای تیم.

بخش اول

مفاهیم

زبان مشترک: کلمه‌هایی که در هر خبر، مقاله و صفحه مدل می‌بینید.

مفاهیم پایه

از یادگیری ماشین تا مدل زبانی بزرگ

مفهوم	یعنی چه
یادگیری ماشین (ML)	به جای نوشتن قانون، به کامپیوتر مثال می‌دهیم تا خودش الگو را پیدا کند.
یادگیری عمیق (Deep Learning)	نوعی یادگیری ماشین با «شبکه عصبی» چندلایه. تقریباً همه مدل‌های امروزی از این نوع‌اند.
مدل زبانی بزرگ (LLM)	شبکه‌ای که با حجم بسیار زیادی متن آموزش دیده و فقط یک کار می‌کند: **پیش‌بینی تکه بعدی متن**. همه توانایی‌هایش (جواب دادن، خلاصه کردن، کد نوشتن) از همین یک کار می‌آید.
ترنسفورمر (Transformer)	معماری (نقشه ساخت) تقریباً همه مدل‌های زبانی امروز. ایده اصلی‌اش «توجه» است.
توجه (Attention)	مدل برای فهم هر کلمه، به همه کلمه‌های قبلی نگاه می‌کند و وزن می‌دهد که کدام مهم‌ترند. هزینه‌اش با طول متن زیاد می‌شود.
چندوجهی (Multimodal)	مدلی که علاوه بر متن، تصویر یا صدا یا ویدیو هم می‌گیرد یا می‌سازد.

توکن، پنجره متن و بردار معنایی

مفهوم	یعنی چه
توکن (Token)	تکه‌ای از متن که مدل با آن کار می‌کند؛ گاهی یک کلمه، گاهی بخشی از کلمه. قیمت و سرعت همه‌جا بر حسب توکن است. **متن فارسی معمولاً توکن بیشتری از همان متن انگلیسی مصرف می‌کند**، پس گران‌تر و کندتر است.
توکن‌ساز (Tokenizer)	برنامه‌ای که متن را به توکن می‌شکند. هر مدل توکن‌ساز خودش را دارد. توکن‌ساز خوب برای فارسی یعنی هزینه کمتر.
پنجره متن (Context window)	بیشترین مقدار متنی (ورودی + خروجی) که مدل در یک بار می‌بیند؛ مثلاً 128K یعنی حدود ۱۲۸ هزار توکن. هر چه خارج از پنجره باشد، برای مدل وجود ندارد.
بردار معنایی (Embedding)	تبدیل متن به یک فهرست عدد، طوری که متن‌های هم‌معنی عددهای نزدیک داشته باشند. پایه جست‌وجوی معنایی و بانک دانش است.
دما (Temperature)	میزان تصادفی بودن جواب. دمای پایین یعنی جواب قابل‌پیش‌بینی‌تر؛ برای کارهای دقیق مثل استخراج داده، دما را پایین بگذارید.

مفهوم	یعنی چه
توهم (Hallucination)	وقتی مدل با اطمینان چیزی می‌گوید که درست نیست. هیچ مدلی از آن خالی نیست؛ باید با طراحی محصول کنترلش کرد.

یک مدل چطور ساخته می‌شود

ساختن یک مدل گفت‌وگو معمولاً سه مرحله دارد:

۱. **پیش‌آموزش** (Pre-training) — مدل روی حجم بسیار زیادی متن، پیش‌بینی کلمه بعد را یاد می‌گیرد. خروجی این مرحله «مدل پایه» (Base) است: زبان را بلد است ولی به سؤال جواب مرتب نمی‌دهد.

۲. **تنظیم با دستور** (SFT / Instruction tuning) — با هزاران نمونه «سؤال ← جواب خوب» یاد می‌گیرد مثل دستیار رفتار کند. خروجی: مدل Instruct یا Chat.

۳. **هم‌راستاسازی با ترجیح** (RLHF، DPO) — به مدل دو جواب نشان می‌دهند و می‌گویند کدام بهتر است. مدل یاد می‌گیرد جواب مفیدتر و امن‌تر بدهد.

مدل‌های استدلالی (Reasoning models) یک مرحله دیگر هم دارند: با یادگیری تقویتی (RL) روی مسئله‌هایی که جواب قابل‌بررسی دارند (ریاضی، کد) یاد می‌گیرند قبل از جواب «فکر کنند». این فکر کردن توکن مصرف می‌کند؛ پس دقیق‌ترند ولی **کندتر و گران‌ترند**. برای گفت‌وگوی صوتی که تأخیر مهم است، معمولاً مدل غیراستدلالی یا حالت فکر کوتاه بهتر است.

تطبیق مدل با کار خودمان

روش	چه وقت	هزینه
نوشتن دستور خوب (Prompting)	همیشه اول از این شروع کنید. با چند مثال در دستور (Few-shot) خیلی از کارها حل می‌شود.	تقریباً صفر
بازیابی + تولید (RAG)	وقتی مدل باید از دانش خود سازمان جواب بدهد (آیین‌نامه، مستندات). متن مرتبط پیدا و کنار سؤال به مدل داده می‌شود. بانک دانش Phoenix همین است.	کم تا متوسط
تنظیم دقیق (Fine-tuning)	وقتی رفتار یا قالب خروجی ثابتی می‌خواهید، یا مدل کوچک باید کار مشخصی را خوب انجام دهد. LoRA روشی ارزان است که فقط بخش کوچکی از وزن‌ها را تغییر می‌دهد.	متوسط (داده + سخت‌افزار)
عامل (Agent) و **استفاده از ابزار** (Tool use)	وقتی مدل باید کاری انجام دهد (ثبت درخواست، فرستادن پیامک، پرس‌وجو از پایگاه داده). مدل تصمیم می‌گیرد کدام ابزار را با چه ورودی صدا بزند. MCP یک قرارداد استاندارد برای وصل کردن ابزارها به مدل است.	متوسط؛ آزمودنش سخت است

اجرای مدل (استنتاج)

استنتاج (Inference) یعنی استفاده از مدل آموزش‌دیده برای جواب دادن. این مفهوم‌ها در انتخاب سرور و هزینه مهم‌اند:

مفهوم	یعنی چه
پارامتر (Parameters)	عددهای داخل مدل که در آموزش تنظیم شده‌اند. 8B یعنی ۸ میلیارد. پارامتر بیشتر معمولاً یعنی تواناتر ولی سنگین‌تر.
کوانتیزه کردن (Quantization)	ذخیره هر عدد با بیت کمتر (مثلاً ۴ بیت به جای ۱۶). مدل کوچک‌تر و سریع‌تر می‌شود و کمی دقت از دست می‌دهد. قاعده سرانگشتی حافظه: **پارامتر × بیت ÷ ۸**؛ مدل ۸B در ۱۶ بیت حدود ۱۶ گیگابایت، در ۴ بیت حدود ۵ گیگابایت.
ترکیب متخصص‌ها (MoE)	مدل از چند «متخصص» ساخته شده و برای هر توکن فقط چند تا فعال می‌شوند. مثلاً 30B-A3B یعنی ۳۰ میلیارد پارامتر کل که ۳ میلیاردش فعال است: **حافظه به اندازه ۳۰B لازم است ولی سرعت نزدیک مدل ۳B است.**
حافظه نهان KV (KV cache)	مدل محاسبه‌های متن قبلی را نگه می‌دارد تا دوباره حساب نکند. متن بلند = حافظه بیشتر روی کارت گرافیک.
تأخیر و توان عملیاتی (Latency / Throughput)	تأخیر: یک کاربر چقدر منتظر می‌ماند. توان: سرور در ثانیه به چند نفر جواب می‌دهد. اغلب یکی را فدای دیگری می‌کنید. برای تلفن، **تأخیر** مهم‌تر است.
دسته‌بندی (Batching)	پردازش هم‌زمان درخواست چند کاربر روی یک کارت گرافیک. موتورهایی مثل vLLM این کار را خودکار می‌کنند.

خواندن Hugging Face

huggingface.co مثل «گیت‌هاب هوش مصنوعی» است: جایی که تقریباً همه مدل‌ها و داده‌های باز منتشر می‌شوند. هر مدل یک «مخزن» دارد با فایل‌های وزن، توکن‌ساز و یک صفحه توضیح به نام **کارت مدل**.

بخش‌های سایت

بخش	چه دارد	چطور استفاده کنید
Models	همه مدل‌ها. فیلتر بر اساس کار (Task)، زبان، مجوز، کتابخانه و اندازه.	فیلتر Languages: Persian و Task: Automatic Speech Recognition را امتحان کنید. مرتب‌سازی با Trending نشان می‌دهد این هفته چه داغ است.
Datasets	داده‌های آموزش و ارزیابی، با پیش‌نمایش ردیف‌ها.	قبل از استفاده، مجوز و نحوه جمع‌آوری را در کارت داده بخوانید.
Spaces	برنامه‌های کوچک قابل اجرا در مرورگر؛ نسخه نمایشی مدل‌ها و همه جدول‌های رتبه‌بندی اینجا هستند.	قبل از نصب هر مدل، اول نسخه نمایشی‌اش را با چند جمله فارسی امتحان کنید.
Papers (Daily Papers)	مقاله‌های روز که جامعه انتخاب کرده، با پیوند به مدل و داده مرتبط.	روزی یک نگاه به عنوان‌ها؛ هفته‌ای یکی را کامل بخوانید.
Collections	فهرست‌های گردآوری‌شده؛ مثلاً همه نسخه‌های یک خانواده مدل.	برای دیدن یک‌جای همه اندازه‌ها و نسخه‌های کوانتیزه.
Learn	دوره‌های رایگان: LLM، صوت، عامل‌ها، تنظیم دقیق.	مسیر یادگیری اصلی در فصل «کجا به‌روز بمانیم».

کارت مدل، فیلد به فیلد

نام مدل خودش نیمی از اطلاعات را می‌دهد. یک نام فرضی را باز می‌کنیم:

Org/ModelName-3.5-30B-A3B-Instruct-AWQ

تکه	یعنی
Org/	سازنده یا کسی که منتشر کرده. اگر سازنده اصلی نیست، احتمالاً نسخه تغییریافته یا کوانتیزه دیگران است.
3.5	نسل و نسخه.
30B-A3B	۳۰ میلیارد پارامتر کل، ۳ میلیارد فعال (مدل MoE).
Base / Chat / Instruct	Instruct و Chat برای گفت‌وگو آماده‌اند. Base برای تنظیم دقیق است، نه برای استفاده مستقیم.

تکه	یعنی
GGUF / GPTQ / AWQ / MLX / FP8	نسخه کوانتیزه یا قالب خاص. GGUF برای llama.cpp و Ollama (لپ‌تاپ و CPU)، AWQ، GPTQ و FP8 برای سرور با کارت گرافیک و vLLM، MLX برای مک.
Q4_K_M، Q8_0	سطح کوانتیزه در GGUF. عدد بعد از Q تعداد بیت است. Q4_K_M تعادل رایج بین اندازه و کیفیت است.

داخل کارت مدل و ستون کناری صفحه، این‌ها را نگاه کنید:

فیلد	چه بپرسید
License (مجوز)	آیا استفاده تجاری مجاز است؟ Apache-2.0 و MIT آزادند. مجوزهای اختصاصی سازنده‌ها (مثل مجوز Llama یا Gemma) شرط دارند. CC-BY-NC یعنی **فقط غیرتجاری** — برای محصول ما قابل استفاده نیست.
Gated	برای دانلود باید فرم پر کنید و شرایط را بپذیرید. گاهی دسترسی از ایران محدود است.
Model size / Tensor type	اندازه و دقت ذخیره (BF16، FP16، FP8، INT4). با قاعده حافظه بالا حساب کنید روی سرور ما جا می‌شود یا نه.
Context length	پنجره متن. معمولاً در فایل config.json با نام max_position_embeddings هم آمده است.
Languages	آیا فارسی (fa) رسماً پشتیبانی می‌شود؟ «چندزبانه» لزوماً یعنی فارسی خوب نیست؛ همیشه خودتان بیازمایید.
Evaluation / Benchmarks	جدول نتایج. مهم: سازنده خودش اندازه گرفته یا کس دیگری؟ با چه تنظیمی (چند مثال، با یا بدون فکر کردن)؟ فصل «بنچمارک‌ها» را ببینید.
Downloads / Likes	نشانه محبوبیت، نه کیفیت. دانلود ماه گذشته را نشان می‌دهد.
Model tree	مدل پایه این مدل چیست و چند نسخه تنظیم‌شده یا کوانتیزه از آن ساخته شده است. برای پیدا کردن نسخه فارسی‌شده یک مدل معروف عالی است.
Files	قالب safetensors امن است. فایل‌های bin. یا pkl. قدیمی ممکن است کد اجرا کنند؛ از مخزن ناشناس دانلود نکنید.
Inference Providers	آیا می‌شود بدون نصب، از طریق سرویس‌دهنده‌ها امتحانش کرد.

کارت داده

- **Splits** — بخش‌های داده: train برای آموزش، validation برای تنظیم، test فقط برای سنجش نهایی. عددی که روی test گزارش شده معتبرتر است.
- **اندازه** — تعداد ردیف یا ساعت صدا. برای صدا: چند گوینده، چه لهجه‌هایی، تلفنی یا میکروفون خوب؟
- **منبع و مجوز** — داده از کجا آمده و آیا اجازه استفاده تجاری دارد.

از کجا بفهمیم یک مخزن قابل اعتماد است

۱. سازنده یک سازمان شناخته‌شده است یا کارت کامل و صادقانه دارد (محدودیت‌ها را هم گفته).

۲. نتایج ارزیابی قابل تکرار است: نام داده، تنظیمات و کد ارزیابی آمده.

۳. مجوز روشن است و با استفاده ما جور است.

۴. فایل‌ها safetensors هستند و اندازه‌شان با تعداد پارامتر ادعایی جور است.

۵. در بخش Community مشکل جدی بی‌جواب نمانده است.

فرهنگ اختصارات

به ترتیب الفبای انگلیسی. ستون آخر می‌گوید معمولاً کجا می‌بینیدش.

اختصار	شکل کامل	معنی ساده	کجا
A3B, A22B	Active params	پارامترهای فعال در مدل MoE	نام مدل
ASR / STT	Automatic Speech Recognition / Speech-to-Text	تبدیل گفتار به متن	صوت
AWQ, GPTQ	Activation-aware / GPT Quantization	دو روش کوانتیزه کردن ۴ بیتی برای کارت گرافیک	نام مدل
BF16, FP16, FP8	Brain Float 16, Floating Point	دقت ذخیره عددها؛ عدد = تعداد بیت	کارت مدل
BLEU, chrF	—	شباهت ترجمه به ترجمه مرجع (بالاتر بهتر)	ترجمه
CER	Character Error Rate	درصد خطا در سطح حرف (پایین‌تر بهتر)	صوت
CoT	Chain of Thought	فکر کردن قدم‌به‌قدم قبل از جواب	بنچمارک
DPO	Direct Preference Optimization	آموزش با «این جواب بهتر از آن است»؛ ساده‌تر از RLHF	مقاله
Elo	—	امتیاز رتبه‌بندی از مقایسه دوبه‌دو، مثل شطرنج	آرنا
EM	Exact Match	جواب دقیقاً با جواب درست یکی است یا نه	بنچمارک
EOU / EOT	End of Utterance / Turn	تشخیص اینکه کاربر حرفش تمام شده	صوت
F1	—	ترکیب دقت و پوشش در یک عدد (۰ تا ۱)	طبقه‌بندی
GGUF	—	قالب فایل llama.cpp و Ollama	نام مدل
GQA, MLA	Grouped-Query / Multi-head Latent Attention	روش‌های کم کردن حافظه توجه	معماری
LoRA, QLoRA	Low-Rank Adaptation	تنظیم دقیق ارزان؛ QLoRA روی مدل کوانتیزه	تنظیم دقیق
MoE	Mixture of Experts	ترکیب متخصص‌ها؛ فقط بخشی از مدل فعال می‌شود	معماری
MOS	Mean Opinion Score	میانگین نمره شنونده‌ها به کیفیت صدا (۱ تا ۵)	صوت
MCP	Model Context Protocol	استاندارد وصل کردن ابزار و داده به مدل	عامل‌ها
NLI	Natural Language Inference	آیا جمله دوم از جمله اول نتیجه می‌شود	بنچمارک
PEFT	Parameter-Efficient Fine-Tuning	نام کلی روش‌هایی مثل LoRA؛ کتابخانه‌ای به همین نام	تنظیم دقیق
PPL	Perplexity	چقدر مدل از متن «تعجب می‌کند» (پایین‌تر بهتر)	مقاله

اختصار	شکل کامل	معنی ساده	کجا
pass@1, pass@k	—	با ۱ یا k بار تلاش، حداقل یک جواب درست بود؟	کد و ریاضی
RAG	Retrieval-Augmented Generation	پیدا کردن متن مرتبط و دادن آن به مدل	محصول
RLHF, RLVR	RL from Human Feedback / Verifiable Rewards	یادگیری تقویتی با نظر انسان / با جواب قابل‌بررسی	مقاله
RoPE	Rotary Position Embedding	روش فهماندن ترتیب کلمه‌ها؛ در افزایش پنجره متن می‌بینید	معماری
RTF, RTFx	Real-Time Factor (inverse)	RTF: زمان پردازش ÷ طول صدا (پایین‌تر بهتر). RTFx برعکس آن است (بالاتر بهتر)	صوت
S2S	Speech-to-Speech	مدلی که صدا می‌گیرد و مستقیم صدا می‌دهد	صوت
SER	Speech Emotion Recognition	تشخیص احساس از صدا	صوت
SFT	Supervised Fine-Tuning	آموزش با نمونه‌های سؤال و جواب درست	کارت مدل
SIM / SECS	Speaker Similarity	شباهت صدای ساخته‌شده به صدای مرجع	صوت
SOTA	State of the Art	بهترین نتیجه شناخته‌شده تا امروز	همه‌جا
TPOT / ITL	Time Per Output Token / Inter-Token Latency	فاصله بین توکن‌های خروجی	استنتاج
TTFT, TTFA	Time To First Token / Audio	چقدر طول می‌کشد اولین توکن یا اولین تکه صدا برسد	استنتاج و صوت
tok/s	Tokens per second	سرعت تولید متن	استنتاج
TTS	Text-to-Speech	تبدیل متن به گفتار	صوت
VAD	Voice Activity Detection	تشخیص اینکه کسی حرف می‌زند یا سکوت است	صوت
VLM	Vision-Language Model	مدلی که تصویر و متن را با هم می‌فهمد	مدل
WER	Word Error Rate	درصد خطا در سطح کلمه (پایین‌تر بهتر)	صوت
0-shot, 5-shot	—	تعداد مثالی که در دستور به مدل داده شده	بنچمارک

موضوع‌های تکمیلی هوش مصنوعی

فصل «مفاهیم پایه» زبان مشترک را داد. این فصل بقیه موضوع‌هایی را فهرست می‌کند که یک عضو تازه تیم باید حداقل یک‌بار درباره‌شان خوانده باشد. برای هر موضوع می‌نویسیم **چیست**، **چرا به Phoenix مربوط است** و **از کجا بخوانیم**.

نقشه یک‌نگاه

موضوع	چرا مهم است	اولویت
نوشتن دستور خوب (Prompting)	ارزان‌ترین راه بهتر کردن رفتار دستیار. همه چیز از اینجا شروع می‌شود.	اول بخوانید
بانک دانش و RAG	دستیار باید از دانش مشتری جواب بدهد، نه از حافظه مدل.	اول بخوانید
ابزار و عامل (Tool use، Agent، MCP)	دستیار باید کار انجام دهد: ثبت درخواست، پیامک، پرس‌وجو.	اول بخوانید
خروجی ساختاریافته	برنامه ما به JSON درست نیاز دارد، نه متن آزاد.	مهم
ارزیابی (Eval)	بدون آن نمی‌دانیم تغییر جدید بهتر شد یا بدتر.	اول بخوانید
تنظیم دقیق (Fine-tuning)	برای مدل کوچک و کار ثابت یا برای کم کردن هزینه.	بعداً
سرو کردن مدل (Serving)	مدل را چطور روی سرور خودمان اجرا کنیم و هزینه چقدر می‌شود.	مهم
ایمنی و حریم خصوصی	صدای مشتری داده حساس است. تزریق دستور و نشت داده خطر واقعی‌اند.	مهم
هزینه و تأخیر	در تماس تلفنی هر ثانیه تأخیر حس می‌شود.	مهم
مجوز مدل (License)	همه مدل‌های «باز» برای استفاده تجاری آزاد نیستند.	مهم
چندوجهی (Vision، Audio)	مدل‌هایی که مستقیم صدا یا تصویر می‌فهمند؛ آینده دستیار صوتی.	بعداً

۱. نوشتن دستور خوب (Prompting)

دستور سیستمی (System prompt) متنی است که رفتار دستیار را تعیین می‌کند: نقش، لحن، قوانین، ابزارها. قاعده‌های ساده:

- **روشن و مشخص بنویسید.** «مؤدب باش» کم است. «همیشه با «شما» صحبت کن و هر جواب را حداکثر در دو جمله بگو» بهتر است.
- **مثال بدهید** (Few-shot). دو یا سه نمونه «ورودی ← خروجی خوب» بیشتر از ده خط توضیح اثر دارد.
- **«نکن» را کم بنویسید.** به جای «اسم رقیب را نیاور» بنویسید «فقط درباره محصولات ما حرف بزن».
- **کار بزرگ را تکه کنید.** یک دستور برای یک کار. چند کار = چند مرحله.
- **دستور را نسخه‌گذاری کنید** مثل کد، و هر تغییر را با ارزیابی بسنجید.

برای صدا: جواب کوتاه بخواهید. شکل لیست، ستاره و جدول در تلفن خوانده نمی‌شود.

Read: Anthropic prompt engineering docs · OpenAI prompting guide · promptingguide.ai

۲. بانک دانش و RAG

RAG یعنی قبل از جواب دادن، متن مرتبط را از بانک دانش پیدا کنیم و کنار سؤال به مدل بدهیم. مراحلش:

مرحله	یعنی چه	خطای رایج
تکه‌کردن (Chunking)	سند را به تکه‌های کوچک (مثلاً ۲۰۰ تا ۵۰۰ توکن) تقسیم می‌کنیم.	تکه‌ای که وسط جمله یا جدول بریده شود.
بردارسازی (Embedding)	هر تکه با مدل بردار معنایی به عدد تبدیل و در پایگاه برداری ذخیره می‌شود.	مدلی که فارسی را خوب نمی‌فهمد.
جست‌وجو (Retrieval)	سؤال هم بردار می‌شود و نزدیک‌ترین تکه‌ها پیدا می‌شوند. ترکیب جست‌وجوی معنایی با جست‌وجوی کلمه‌ای (BM25) به آن **جست‌وجوی ترکیبی** (Hybrid) می‌گویند.	فقط معنایی؛ اسم و کد محصول را گم می‌کند.
بازرتبه‌بندی (Reranker)	مدل کوچکی ۲۰ تکه اول را دوباره و دقیق‌تر مرتب می‌کند و ۳ تا ۵ تکه بهتر را نگه می‌دارد.	حذف این مرحله؛ اغلب بزرگ‌ترین جهش کیفیت را می‌دهد.
تولید جواب	تکه‌ها در دستور می‌روند و مدل فقط با آن‌ها جواب می‌دهد، با ارجاع به منبع.	اجازه دادن به مدل که وقتی جواب در تکه‌ها نیست «حدس بزند».

> **اشتباه معمول:** وقتی RAG بد جواب می‌دهد، اغلب مدل زبانی مقصر نیست؛ **جست‌وجو** تکه درست را پیدا نکرده. اول بسنجید «تکه درست در ۵ نتیجه اول بود؟»، بعد سراغ مدل بروید.

Read: Anthropic "Contextual Retrieval" · Hugging Face Advanced RAG cookbook · LlamaIndex / LangChain RAG docs

۳. ابزار، عامل و MCP

- **صدا زدن ابزار** (Tool / Function calling): شما فهرست ابزارها را با توضیح و ورودی‌ها به مدل می‌دهید. مدل به جای متن، یک «درخواست صدا زدن ابزار» با ورودی‌های JSON برمی‌گرداند. برنامه شما ابزار را اجرا می‌کند و نتیجه را به مدل برمی‌گرداند.
- **عامل** (Agent): مدلی که در یک حلقه چند بار ابزار صدا می‌زند تا کار تمام شود. هر چه مراحل بیشتر باشد، احتمال خطا بیشتر است (۹۰٪ در هر مرحله، بعد از ۱۰ مرحله فقط حدود ۳۵٪ درست).
- **MCP** (Model Context Protocol): استاندارد باز برای وصل کردن ابزار و داده به هر مدل؛ یک‌بار ابزار را می‌نویسید، همه جا کار می‌کند.
- **چند عامل** (Multi-agent): چند مدل با نقش‌های جدا. قدرتمند ولی پرهزینه و سخت‌اشکال‌یابی؛ اول با یک عامل ساده شروع کنید.

قاعده‌های ایمنی برای ابزار: ابزارهای خطرناک (پرداخت، حذف) تأیید انسان بخواهند؛ ورودی ابزار را همیشه اعتبارسنجی کنید؛ مدل را مجبور به حدس نکنید، بگذارید بپرسد.

Read: Anthropic "Building effective agents" · modelcontextprotocol.io · BFCL / τ-bench papers

۴. خروجی ساختاریافته

وقتی برنامه به JSON نیاز دارد، «لطفاً JSON بده» کافی نیست. روش‌های مطمئن: **حالت JSON / طرح‌واره** (Structured outputs، JSON schema در API، یا **رمزگشایی محدود** (Constrained decoding) در سرورهایی مثل vLLM که مدل را مجبور می‌کند فقط توکن‌های مجاز تولید کند. بعد از آن هم همیشه خروجی را با کد اعتبارسنجی کنید.

۵. ارزیابی (Eval)

ارزیابی برای مدل‌ها همان تست واحد برای کد است. مجموعه‌ای از نمونه‌های واقعی با «جواب خوب» روشن می‌سازید و بعد از هر تغییر (مدل، دستور، RAG) دوباره اجرا می‌کنید.

روش	چه وقت
معیار دقیق	جواب یک مقدار مشخص دارد: دسته‌بندی، استخراج، WER، درست‌بودن ابزار.
مدل به‌عنوان داور (LLM-as-judge)	جواب آزاد است (لحن، مفید بودن). یک مدل قوی با یک فهرست معیار نمره می‌دهد. داور سوگیری دارد (جواب بلند را دوست دارد)؛ ۲۰ نمونه را خودتان هم نمره بدهید و با داور مقایسه کنید.
ارزیابی انسانی	برای تصمیم‌های مهم و برای اعتبارسنجی داور. گران ولی قابل‌اعتمادترین.
آزمون روی تماس واقعی	تماس‌های ضبط‌شده با اجازه، بازپخش روی نسخه جدید. بهترین سیگنال برای محصول صوتی.

Read: Hamel Husain "Your AI product needs evals" · Eugene Yan "Task-specific LLM evals" · Hugging Face LLM course

۶. تنظیم دقیق در عمل

- اول **دستور خوب + RAG** را امتحان کنید. فقط اگر کافی نبود، سراغ تنظیم دقیق بروید.
- **داده باکیفیت از داده زیاد مهم‌تر است.** ۵۰۰ تا ۵۰۰۰ نمونه تمیز معمولاً کافی است.
- ابزارها: Hugging Face TRL، PEFT، Unsloth، Axolotl، LLaMA-Factory.
- **تقطیر** (Distillation): جواب مدل بزرگ را برای آموزش مدل کوچک استفاده می‌کنیم تا ارزان‌تر شود. مجوز مدل بزرگ را بررسی کنید.
- بعد از تنظیم دقیق حتماً دوباره ارزیابی کنید؛ ممکن است مدل چیزهای دیگر را فراموش کند.

۷. سرو کردن مدل (Serving)

ابزار	کاربرد
vLLM	موتور استاندارد سرور برای مدل زبانی روی کارت گرافیک؛ دسته‌بندی خودکار، رمزگشایی محدود. اولین انتخاب برای تولید.
SGLang, TensorRT-LLM	رقیب‌های سریع vLLM؛ برای بار سنگین و بهینه‌سازی سخت‌افزار انویدیا.
llama.cpp, Ollama, LM Studio	اجرا روی لپ‌تاپ و CPU با قالب GGUF. عالی برای آزمایش؛ برای بار زیاد مناسب نیست.

ابزار	کاربرد
Triton, Ray Serve, KServe	مدیریت چند مدل و مقیاس‌دهی در Kubernetes.
Hugging Face TGI / Inference Endpoints	سرویس آماده برای سرو؛ ساده‌تر ولی کم‌انعطاف‌تر.

برای برآورد حافظه: وزن‌ها (پارامتر × بیت ÷ ۸) + حافظه نهان KV + حدود ۲۰٪ سربار. برای تماس تلفنی، ابتدا **TTFT** و بعد **توان عملیاتی** را بسنجید.

۸. ایمنی و حریم خصوصی

خطر	یعنی چه و چه کنیم
تزریق دستور (Prompt injection)	متنی که از بیرون می‌آید (سند، ایمیل، صحبت مشتری) به مدل دستور می‌دهد: «قوانین قبلی را فراموش کن». ورودی بیرونی را «داده» بدانید، نه «دستور»؛ ابزارهای خطرناک را محدود کنید.
نشت داده	دستیار اطلاعات مشتری A را به مشتری B می‌گوید. دسترسی را در کد کنترل کنید، نه در دستور.
توهم	جواب ساختگی. با RAG، ارجاع به منبع و «نمی‌دانم» گفتن کنترل می‌شود.
داده صوتی	صدا اطلاعات شخصی و حتی زیستی است. رضایت، مدت نگهداری و پنهان‌سازی (PII redaction) را از اول طراحی کنید.
سوءاستفاده از صدا	شبیه‌سازی صدا (Voice cloning) برای کلاهبرداری. فقط با رضایت مکتوب.
نرده‌های ایمنی (Guardrails)	فیلتر ورودی و خروجی (مثلاً Llama Guard، NeMo Guardrails) به‌علاوه تست حمله‌ای (Red teaming).

Read: OWASP Top 10 for LLM Applications · NIST AI RMF

۹. هزینه و تأخیر

- قیمت API بر حسب **میلیون توکن** است و ورودی و خروجی جدا قیمت دارند؛ خروجی چند برابر گران‌تر است.
- **ذخیره دستور** (Prompt caching): قسمت ثابت دستور (مثلاً دستور سیستمی) ارزان‌تر و سریع‌تر حساب می‌شود.
- **مدل کوچک برای کار ساده**: مسیریابی بین مدل کوچک و بزرگ (Routing) هزینه را چند برابر کم می‌کند.
- **پخش زنده** (Streaming): جواب را تکه‌تکه به TTS بدهید، منتظر پایان جواب نمانید.
- تأخیر کل = پایان نوبت + TTFA + TTFT + ASR + شبکه. هر کدام را جدا اندازه بگیرید.

۱۰. مجوز مدل

مجوز	یعنی چه
Apache 2.0, MIT	آزاد؛ استفاده تجاری و تغییر مجاز است. بهترین حالت.
مجوزهای سفارشی (مثل Llama، نسخه‌های قدیمی Gemma)	استفاده تجاری مجاز ولی با شرط: سقف تعداد کاربر، منع بعضی کاربردها، یا ذکر نام. متن را بخوانید.

مجوز	یعنی چه
CC-BY-NC, «non-commercial»	**استفاده تجاری ممنوع.** فقط برای پژوهش و آزمایش.
مدل بسته (API)	وزن‌ها را ندارید؛ فقط از API استفاده می‌کنید. شرایط نگهداری داده و دسترسی از ایران را بررسی کنید.

> **یادآوری:** مجوز مدل، مجوز داده آموزش و مجوز مدل‌های وابسته (مثلاً تقطیر از یک مدل بسته) سه چیز جدا هستند. پیش از استفاده تجاری، همیشه صفحه LICENSE را بخوانید.

۱۱. چندوجهی

- **مدل تصویر-زبان** (VLM): عکس یا اسکنر سند را می‌فهمد؛ مثلاً خواندن فرم و فاکتور.
- **مدل صوتی-زبانی** (Audio LLM): به جای ASR جدا، صدا را مستقیم می‌شنود و لحن و احساس را هم می‌فهمد.
- **صدا به صدا** (Speech-to-speech، Realtime): یک مدل برای شنیدن، فکر کردن و حرف زدن؛ تأخیر خیلی کم، ولی کنترل کمتر روی هر مرحله و فارسی ضعیف‌تر.
- زنجیره جدا (ASR ← LLM ← TTS) هنوز برای Phoenix **قابل‌کنترل‌تر و قابل‌سنجش‌تر** است؛ ولی روند به سمت مدل‌های یکپارچه است، پس دنبالش کنید.

مسیر مطالعه پیشنهادی (به ترتیب)

۱. دوره رایگان LLM در Hugging Face (فصل‌های ۱ تا ۴).

۲. راهنمای Prompt Engineering از Anthropic یا OpenAI.

۳. مقاله «Building effective agents» (Anthropic).

۴. مقاله Contextual Retrieval + یک آموزش عملی RAG.

۵. مقاله «Your AI product needs evals» (Hamel Husain).

۶. دوره‌های «Intro to LLMs» :Andrej Karpathy و «Let's build GPT» (برای فهم عمیق).

۷. دوره صوت Hugging Face (برای ASR و TTS).

بخش دوم

عددها

هر جدول رتبه‌بندی چه چیزی را اندازه می‌گیرد و کجا گولمان می‌زند.

بنچمارک‌ها و معیارها

بنچمارک (Benchmark) یک آزمون استاندارد است: مجموعه‌ای سؤال با جواب درست. **معیار** (Metric) عددی است که از آزمون درمی‌آید (مثلاً درصد درست). **جدول رتبه‌بندی** (Leaderboard) نتیجه چند مدل روی یک یا چند آزمون است.

مهم‌ترین بنچمارک‌های مدل زبانی

نام	چه چیزی را می‌سنجد	مراقب باشید
MMLU, MMLU-Pro	دانش عمومی در ۵۷ رشته، چهارگزینه‌ای (Pro: ده‌گزینه‌ای و سخت‌تر)	MMLU تقریباً اشباع شده؛ همه مدل‌های بزرگ نمره بالا دارند.
GPQA Diamond	سؤال‌های علمی سطح دکترا که با جست‌وجو هم سخت پیدا می‌شوند	فقط ۱۹۸ سؤال؛ اختلاف چند درصدی ممکن است تصادفی باشد.
HLE	Humanity's Last Exam: سؤال‌های بسیار سخت از متخصص‌ها	برای مقایسه مدل‌های پیشرو؛ برای کار روزمره کم‌ربط.
AIME, MATH	ریاضی مسابقه‌ای	نشانه توان استدلال، نه توان گفت‌وگو.
LiveCodeBench, SWE-bench	نوشتن کد؛ SWE-bench رفع مشکل واقعی در مخزن‌های گیت‌هاب	نسخه Verified یا Pro را با هم مقایسه نکنید.
IFEval	اجرای دقیق دستور («در ۳ جمله»، «بدون ویرگول»)	برای محصول ما مهم است: دستیار باید قالب را رعایت کند.
BFCL, τ-bench	صدا زدن درست ابزار؛ τ-bench گفت‌وگوی چندمرحله‌ای با کاربر شبیه‌سازی‌شده و قوانین کسب‌وکار	**نزدیک‌ترین بنچمارک به دستیار Phoenix** (پرسیدن، ابزار، رعایت سیاست).
RULER, Needle	استفاده واقعی از متن بلند	پنجره ۱ میلیون توکنی لزوماً یعنی استفاده خوب از همه آن نیست.
MTEB	کیفیت بردار معنایی در جست‌وجو، دسته‌بندی و خوشه‌بندی	برای بانک دانش. نسخه فارسی هم دارد (پایین ببینید).
LMArena	رأی کاربران بین دو جواب ناشناس؛ امتیاز Elo	سلیقه کاربران را می‌سنجد؛ جواب‌های بلند و قالب‌بندی‌شده رأی بیشتری می‌گیرند. «کنترل سبک» را روشن کنید.

چرا یک عدد کافی نیست

مشکل	یعنی چه
آلودگی (Contamination)	سؤال‌های آزمون در داده آموزش بوده؛ مدل جواب را حفظ کرده، نفهمیده. بنچمارک‌های «زنده» که مدام سؤال تازه می‌گیرند (مثل LiveCodeBench) این مشکل را کم می‌کنند.
اشباع (Saturation)	همه مدل‌ها نزدیک ۹۰٪ یا بالاتر؛ دیگر فرقی نشان نمی‌دهد.
تنظیم متفاوت	یک مدل با ۵ مثال و فکر کردن، دیگری بدون مثال. عددها قابل مقایسه نیستند. در جدول دنبال 0-shot، CoT، thinking، pass@1 بگردید.
بازه اطمینان	در آرنا کنار هر امتیاز «±» آمده. اگر بازه دو مدل هم‌پوشانی دارد، عملاً هم‌رتبه‌اند.
گزارش سازنده	عدد کارت مدل را خود سازنده اندازه گرفته. عدد مستقل (Artificial Analysis، Epoch AI، آرنا) معتبرتر است.
زبان	تقریباً همه بنچمارک‌ها انگلیسی‌اند. نمره بالا در انگلیسی تضمین فارسی خوب نیست.

قاعده طلایی: جدول‌ها فقط فهرست کوتاه می‌سازند. تصمیم نهایی با **آزمون روی داده خودمان** است: ۵۰ تا ۲۰۰ نمونه واقعی فارسی از کار Phoenix، با معیار روشن.

جدول‌های فارسی

جدول	چه دارد
Open Persian LLM Leaderboard huggingface.co/spaces/PartAI/open-persian-llm-leaderboard	سنجش مدل‌های زبانی روی آزمون‌های فارسی؛ کار مشترک دانشگاه امیرکبیر و پارت.
Persian LLM Alignment Leaderboard mcilab-llm-alignment-evaluation.hf.space	سنجش هم‌راستایی مدل‌ها (ایمنی، انصاف، ارزش‌ها) به فارسی.
FaMTEB (در MTEB)	نسخه فارسی MTEB برای مدل‌های بردار معنایی؛ مستقیم به کار بانک دانش می‌آید.
Open Persian ASR Leaderboard navidved-open-persian-asr-leaderboard.hf.space	مقایسه مدل‌های گفتار به متن فارسی با WER و CER روی چند داده (Common Voice، یوتیوب فارسی و...).

فصل ویژه صدا

Phoenix یک زنجیره صوتی است: **تشخیص گفتار ← گفتار به متن ← مدل زبانی ← متن به گفتار**، به‌علاوه تشخیص پایان نوبت. پایه‌های این زنجیره در «پرونده فنی» (TECHNICAL_DOSSIER_FA، بخش مبانی صوت) آمده است. اینجا فقط **عددها** را یاد می‌گیریم.

گفتار به متن (ASR / STT)

WER = (کلمه‌های جاافتاده + کلمه‌های اضافه + کلمه‌های اشتباه) ÷ تعداد کلمه‌های متن درست. مثال: متن درست «می‌خواهم مرخصی بگیرم» (۳ کلمه)، مدل نوشته «میخوام مرخصی بگیرم». اگر «میخوام» اشتباه حساب شود، ۳۳٪ ≈ ۳ ÷ ۱ = WER.

> **چرا برای فارسی CER را هم ببینید:** در فارسی نیم‌فاصله («می‌خواهم» یا «میخواهم»)، «ی» و «ک» عربی، و نوشتار محاوره‌ای («میخوام») باعث می‌شود WER بی‌دلیل بالا برود، در حالی که معنی درست است. CER حساسیت کمتری دارد. مهم‌تر از آن: **قبل از حساب کردن، هر دو متن را یکسان‌سازی (Normalization) کنید** — یک شکل برای ی و ک، نیم‌فاصله، عددها و علامت‌ها. جدول‌های معتبر روش یکسان‌سازی را اعلام می‌کنند.

معیار	یعنی	برای Phoenix
WER / CER	درصد خطا (پایین‌تر بهتر)	روی صدای **تلفنی ۸ کیلوهرتز** بسنجید، نه صدای استودیو. فرق می‌تواند چند برابر باشد.
RTFx	چند برابر سریع‌تر از زمان واقعی. RTFx = ۱۰۰ یعنی یک دقیقه صدا در ۰٫۶ ثانیه	برای تحلیل تماس (CCA) که دسته‌ای کار می‌کند، مهم است.
تأخیر جریانی	در حالت زنده (Streaming)، چقدر پس از گفتن، متن می‌رسد	برای تلفن‌گو (IVA) از WER هم مهم‌تر است.
Short-form / Long-form	صدای کوتاه (چند ثانیه) یا طولانی (یک تماس کامل)	تحلیل تماس = بلند؛ گفت‌وگوی زنده = کوتاه.
Diarization (DER)	جدا کردن «چه کسی کی حرف زد»؛ DER نرخ خطای آن	در تماس‌های تک‌کاناله لازم است.

متن به گفتار (TTS)

معیار	یعنی
MOS	شنونده‌ها از ۱ تا ۵ نمره می‌دهند. بالای ۴ یعنی طبیعی. پرهزینه و کند است.
CMOS	مقایسه دو صدا کنار هم: کدام بهتر و چقدر. حساس‌تر از MOS.
UTMOS و مانند آن	مدلی که MOS را خودکار تخمین می‌زند. برای مقایسه سریع خوب است، ولی روی فارسی کمتر آزموده شده.

معیار	یعنی
WER معکوس (وضوح)	صدای ساخته‌شده را دوباره با ASR به متن تبدیل می‌کنند؛ اگر WER پایین بود، صدا واضح است. اشتباه تلفظ عددها و نام‌ها را پیدا می‌کند.
SIM	شباهت صدا به گوینده مرجع (در شبیه‌سازی صدا).
TTFA	زمان تا اولین تکه صدا. برای تلفن، زیر چند صد میلی‌ثانیه هدف خوبی است.
Elo آرنا	رأی شنونده‌ها بین دو صدا (TTS Arena، Artificial Analysis Speech Arena).

تشخیص گفتار و نوبت (VAD، Turn detection)

معیار	یعنی
تأخیر پایان نوبت	از لحظه‌ای که کاربر ساکت شد تا لحظه‌ای که سیستم فهمید نوبت اوست. کم = سریع، ولی…
قطع نابه‌جا (False endpoint)	…سیستم وسط مکث کاربر («خب… راستش…») حرفش را قطع کند. این دو با هم معامله می‌شوند.
قطع‌کردن کاذب (False barge-in)	صدای «اوهوم» یا نویز باعث شود دستیار ساکت شود.
تأخیر کل پاسخ (Voice-to-voice latency)	از پایان حرف کاربر تا شنیدن اولین صدای دستیار. مجموع: پایان نوبت + TTFT + ASR + مدل زبانی + TTFA. **مهم‌ترین عدد تجربه کاربر در تلفن.**

ربط به Phoenix: آخرین تغییر مخزن (کامیت 537415cb8) تشخیص پایان نوبت در AIVA را با پرسیدن از مدل زبانی («آیا جمله کامل است؟») بهتر کرده است. این دقیقاً معامله «تأخیر پایان نوبت» و «قطع نابه‌جا» است؛ برای سنجیدنش هر دو عدد را با هم گزارش کنید.

جدول‌های صوت

جدول	چه دارد
Open ASR Leaderboard (Hugging Face) huggingface.co/spaces/hf-audio/open_asr_leaderboard	بیش از ۶۰ مدل باز و تجاری روی ۱۱ داده؛ WER و RTFx با یکسان‌سازی استاندارد؛ بخش چندزبانه و بلند. فارسی در بخش چندزبانه نیست؛ برای فارسی جدول فارسی بالا را ببینید.
Artificial Analysis — Speech artificialanalysis.ai	سنجش مستقل گفتار به متن (دسته‌ای و جریانی)، متن به گفتار (آرنا) و گفتار به گفتار؛ با قیمت و سرعت.
TTS Arena V2 huggingface.co/spaces/TTS-AGI/TTS-Arena-V2	رأی دوبه‌دو شنونده‌ها با Elo.

بخش سوم

مدل‌ها

خانواده مدل‌های معروف، هر کدام برای چه کاری خوب است و برای Phoenix کدام را اول امتحان کنیم.

فهرست مدل‌های معروف و کاربرد آن‌ها

قبل از خواندن: این فهرست بر اساس **خانواده** است، نه نسخه دقیق. هر چند هفته یک نسخه تازه می‌آید. وضعیت این فصل مهر ۱۴۰۵ است و بخشی از آن از منابع ثانویه (وبلاگ‌ها و تجمیع‌کننده‌ها) آمده. **قبل از هر تصمیم، کارت مدل رسمی و مجوز را در Hugging Face بخوانید.** ستون «نسخه‌های اخیر» فقط برای این است که بدانید دنبال چه اسمی بگردید.

چطور اسم یک مدل را بخوانیم

مثال: Qwen3-30B-A3B-Instruct-2507-FP8 یعنی خانواده Qwen، نسل ۳، ۳۰ میلیارد پارامتر کل با ۳ میلیارد فعال (MoE)، نسخه گفت‌وگو (Instruct)، ساخته‌شده در ماه ۷ سال ۲۰۲۵، با دقت ۸ بیت. اختصارها در فصل فرهنگ اختصارات هستند.

۱. مدل‌های زبانی باز (Open-weight LLM)

«باز» یعنی وزن‌ها را دانلود می‌کنید و روی سرور خودتان اجرا می‌کنید. این برای حریم خصوصی و هزینه مهم است.

خانواده	سازنده	اندازه‌ها و مجوز	کاربرد اصلی و نقطه قوت	مراقب باشید
Qwen (Qwen3، 3.5، 3.6)	Alibaba	از زیر ۱B تا صدها B؛ هم متراکم هم MoE (مثلاً 30B-A3B، 35B-A3B). بیشتر نسخه‌ها Apache 2.0.	**همه‌کاره و چندزبانه.** گفت‌وگو، کد، ریاضی، استدلال، صدا زدن ابزار. خانواده بزرگی دارد: مدل متنی، تصویری (Qwen-VL)، کد (Qwen-Coder)، بردار معنایی، ASR و TTS. **اولین نامزد برای دستیار فارسی.**	کیفیت فارسی را روی داده خودتان بسنجید. نسخه‌های سنگین فکر می‌کنند و کندتر می‌شوند.
Gemma (Gemma 3، 3n، 4)	Google	از حدود ۱B تا حدود ۳۰B؛ نسخه‌های «E» برای دستگاه کوچک. نسل ۴ گزارش شده با Apache 2.0 (نسل‌های قدیمی‌تر مجوز سفارشی داشتند).	**مدل کوچک و کارآمد.** چندزبانه خوب (۱۰۰+ زبان)، چندوجهی (تصویر و در بعضی نسخه‌ها صدا)، پنجره متن بلند. برای یک کارت گرافیک معمولی و دستگاه‌های لبه مناسب است.	مجوز هر نسل را جدا بخوانید. در کار ابزار و کد معمولاً از Qwen عقب‌تر است.
Llama (Llama 3.x، 4)	Meta	۱B تا صدها B؛ Llama 4 به شکل MoE. مجوز سفارشی Llama Community License.	**اکوسیستم بزرگ.** بیشترین ابزار، آموزش و نسخه‌های تنظیم‌شده در جامعه. پایه خوب برای تنظیم دقیق. Llama Guard برای ایمنی.	مجوز شرط دارد (سقف کاربر، ذکر نام). فارسی رسمی پشتیبانی نمی‌شود، باید سنجید.

خانواده	سازنده	اندازه‌ها و مجوز	کاربرد اصلی و نقطه قوت	مراقب باشید
DeepSeek (V3، R1، V4)	DeepSeek	خیلی بزرگ (صدها B، MoE). بیشتر نسخه‌ها MIT. نسخه‌های «Distill» کوچک‌تر هم هستند.	**استدلال و کد با هزینه پایین.** R1 مدل استدلالی باز معروف بود. برای تحلیل سخت، ریاضی و برنامه‌نویسی. تقطیرها روی Qwen/Llama برای سخت‌افزار کوچک.	برای اجرای کامل کلاستر چند-GPU لازم است. در تلفن، فکر کردن طولانی = تأخیر.
Mistral (Small، Medium، Large، Mixtral، Ministral)	Mistral AI	کوچک تا بزرگ؛ بعضی Apache 2.0، بعضی مجوز تحقیقاتی یا فقط API.	**مدل اروپایی، سریع و کارآمد.** زبان‌های اروپایی، فراخوانی ابزار، کد (Codestral، Devstral)، صدا (Voxtral).	فارسی متوسط. مجوز هر مدل متفاوت است.
gpt-oss	OpenAI	دو اندازه حدود ۲۰B و ۱۲۰B (MoE)، Apache 2.0.	**استدلال و ابزار**؛ سطح فکر کردن قابل تنظیم (کم/متوسط/زیاد). فقط متنی.	انگلیسی‌محور؛ فارسی ضعیف‌تر.
GLM (GLM-4.x، 5)	Zhipu / Z.ai	متوسط تا بزرگ (MoE)، معمولاً مجوز آزاد.	**کد و عامل‌ها** (کار چندمرحله‌ای با ابزار). در جدول‌های کد و عامل بالاست.	بیشتر چینی-انگلیسی.
Kimi (K2، K3)	Moonshot AI	خیلی بزرگ (بیش از هزار میلیارد، MoE)؛ مجوز اصلاح‌شده MIT.	**عامل‌ها و کد، متن بلند.** نزدیک به مدل‌های بسته پیشرو در بعضی آزمون‌ها.	سخت‌افزار بسیار سنگین؛ عملاً از طریق API یا سرویس میزبان.
MiniMax	MiniMax	بزرگ، MoE؛ مجوز آزاد در نسخه‌های اخیر.	**عامل و کد، متن بسیار بلند.**	سنگین.
Phi	Microsoft	کوچک (چند B)، MIT.	**مدل خیلی کوچک و خوب در ریاضی/استدلال.** برای دستگاه‌های ضعیف و آزمایش.	دانش عمومی و چندزبانگی محدود.
OLMo، SmolLM، Granite	AI2، Hugging Face، IBM	کوچک تا متوسط؛ Apache 2.0.	**کاملاً باز** (داده و کد آموزش هم منتشر شده). OLMo برای پژوهش و شفافیت؛ SmolLM برای دستگاه کوچک؛ Granite برای سازمان‌ها.	معمولاً از Qwen/Llama ضعیف‌ترند.
مدل‌های فارسی (مثلاً Dorna، PersianMind، Sialk…)	جامعه ایرانی و شرکت‌ها	معمولاً تنظیم‌شده روی Llama/Qwen/Gemma؛ مجوز از پایه ارث می‌برد.	**بهبود فارسی روی مدل‌های پایه.** جدول Open Persian LLM Leaderboard را نگاه کنید.	کیفیت ناهمگون؛ اغلب از مدل پایه عمومی جدیدتر عقب می‌ماند. حتماً بسنجید.

۲. مدل‌های بسته (فقط API)

وزن‌ها در دسترس نیست. معمولاً قوی‌ترین مدل‌ها هستند و راه سریع برای نمونه‌سازی. هزینه، حریم خصوصی و دسترسی را بسنجید.

خانواده	سازنده	کاربرد و نکته
Claude (Fable، Opus، Sonnet، Haiku)	Anthropic	کد، عامل‌ها، متن بلند، پیروی دقیق از دستور. Haiku سریع و ارزان برای کارهای زیاد.
GPT	OpenAI	همه‌کاره؛ API صوتی زنده (Realtime)، تصویر، ابزار. مدل‌های «o» و GPT جدید برای استدلال.
Gemini	Google	پنجره متن خیلی بلند، چندوجهی (ویدیو، صدا، تصویر)، ارتباط با Google Cloud. Gemini Live برای صدا. Flash برای سرعت و قیمت.

خانواده	سازنده	کاربرد و نکته
Grok	xAI	گفت‌وگو و استدلال؛ دسترسی به داده X.
Command	Cohere	RAG و کار سازمانی؛ مدل Embed و Rerank معروف.

۳. مدل‌های بردار معنایی و بازرتبه‌بندی (برای RAG)

مدل	کاربرد و نکته
Qwen3-Embedding / Reranker	چندزبانه و قوی؛ اندازه‌های ۰٫۶B تا ۸B. نامزد اول برای فارسی.
BGE-M3 (BAAI)	چندزبانه، سه نوع جست‌وجو در یک مدل (معنایی، کلمه‌ای، چندبرداری)، متن بلند. انتخاب محبوب و امن.
multilingual-e5 (Microsoft)	سبک و پرکاربرد برای زبان‌های زیاد.
EmbeddingGemma	کوچک (حدود ۳۰۰M) و کارآمد برای دستگاه کوچک.
Jina v3/v4، Nomic Embed	متن بلند و چندوجهی؛ مجوز را بخوانید.
BGE-reranker، Cohere Rerank	بازرتبه‌بندی نتایج جست‌وجو. معمولاً بیشترین بهبود را برای هزینه کم می‌دهد.

برای انتخاب نهایی، نتیجه FaMTEB را نگاه کنید و بعد روی سؤال‌های واقعی خودتان بسنجید.

۴. گفتار به متن (ASR)

مدل	کاربرد و نکته
Whisper (large-v3، turbo)	OpenAI، MIT. چندزبانه (۹۹+ زبان). استاندارد پایه. **turbo** سریع‌تر. فارسی قابل‌قبول ولی روی صدای تلفنی ممکن است ضعیف باشد. با faster-whisper سریع‌تر اجرا می‌شود.
Qwen3-ASR	۰٫۶B و ۱٫۷B، Apache 2.0؛ حدود ۵۰ زبان و گویش. تازه؛ روی صدای فارسی بسنجید.
NVIDIA Canary / Parakeet	از بهترین‌ها در Open ASR Leaderboard برای انگلیسی؛ بسیار سریع. فارسی محدود؛ بسنجید.
Meta MMS / SeamlessM4T	پوشش بسیار زیاد زبان‌ها، ترجمه گفتار. مجوز غیرتجاری در بعضی نسخه‌ها.
Voxtral (Mistral)	مدل صوتی-زبانی و ASR باز.
مدل‌های فارسی تنظیم‌شده	نسخه‌های Whisper تنظیم‌شده روی فارسی؛ Open Persian ASR Leaderboard را ببینید.
سرویس‌های ابری	Google/Azure STT، ElevenLabs Scribe، AssemblyAI، Deepgram. پخش زنده و تأخیر کم؛ پشتیبانی از فارسی را بررسی کنید.

۵. متن به گفتار (TTS)

مدل	کاربرد و نکته
Qwen3-TTS	حدود ۱٫۷B، Apache 2.0؛ چند زبان، شبیه‌سازی صدا از چند ثانیه نمونه. تازه؛ فارسی را بسنجید.
Kokoro	فقط ۸۲M، Apache 2.0؛ فوق‌العاده سبک و سریع، روی CPU هم اجرا می‌شود. فارسی رسمی ندارد.
Chatterbox	MIT؛ شبیه‌سازی صدا و حالت‌های احساسی، چندزبانه.
XTTS-v2 (Coqui)	شبیه‌سازی صدا، چندزبانه از جمله فارسی؛ مجوز غیرتجاری (CPML)، پس برای محصول تجاری مناسب نیست مگر مجوز بگیرید.
F5-TTS، Fish Speech، Orpheus، Piper، Dia	گزینه‌های باز دیگر با کیفیت و مجوز متفاوت. Piper سبک و آفلاین است.
مدل‌های فارسی	به‌دنبال TTS فارسی در Hugging Face با فیلتر Languages: Persian بگردید؛ کیفیت و مجوز بسیار متفاوت است.
سرویس‌های ابری	ElevenLabs، OpenAI TTS، Azure، Google. کیفیت بالا؛ فارسی و هزینه را بسنجید.

برای صدا مقایسه بشنوید: TTS Arena V2 و Artificial Analysis Speech Arena.

۶. تشخیص صحبت و نوبت (VAD و Turn detection)

مدل	کاربرد
Silero VAD	سبک، سریع، MIT؛ استاندارد عملی برای تشخیص صحبت/سکوت.
TEN VAD، WebRTC VAD	گزینه‌های سبک دیگر.
LiveKit turn detector، Pipecat Smart Turn	مدل‌های کوچک متن/صدا برای تشخیص «کاربر حرفش را تمام کرد»؛ فقط سکوت کافی نیست.

۷. تصویر، سند و کد

نوع	مدل‌های معروف
تصویر-زبان (VLM)	Qwen-VL، Gemma (چندوجهی)، Llama 4، InternVL، Pixtral، MiniCPM-V
خواندن سند و OCR	Qwen-VL، olmOCR، DeepSeek-OCR، PaddleOCR، Docling، Surya
تولید تصویر	FLUX، Stable Diffusion، Qwen-Image (باز)؛ Imagen، GPT-image (بسته)
کد	Qwen-Coder، Devstral، Codestral، DeepSeek، GLM، Kimi

کدام مدل برای کدام کار؟

کار	شروع پیشنهادی	نکته
گفت‌وگوی صوتی فارسی (مغز دستیار)	مدل متوسط و سریع، غیراستدلالی: خانواده Qwen (۳۰ تا ۳۵B با MoE فعال ۳B) یا Gemma؛ مدل بسته مثل Claude Haiku/Sonnet یا Gemini Flash برای مقایسه.	TTFT کم و ابزار درست. روی تماس‌های واقعی فارسی بسنجید.
صدا زدن ابزار و کار چندمرحله‌ای	Qwen، GLM، gpt-oss یا مدل بسته (Claude، GPT).	با BFCL و τ-bench و نمونه‌های خودتان بسنجید.
تحلیل پس از تماس (خلاصه، امتیاز، کشف موضوع)	مدل بزرگ‌تر و دقیق‌تر، حتی استدلالی؛ تأخیر مهم نیست.	می‌شود دسته‌ای و شبانه اجرا کرد؛ ارزان‌تر.
بانک دانش (RAG)	بردار: Qwen3-Embedding یا BGE-M3؛ بازرتبه: BGE-reranker؛ تولید: همان مدل گفت‌وگو.	اول کیفیت جست‌وجو را بسنجید.
تبدیل صدا به متن	Whisper large-v3/turbo، Qwen3-ASR؛ سرویس ابری برای مقایسه؛ مدل فارسی تنظیم‌شده.	WER/CER روی ۲۰ قطعه صدای تلفنی خودتان.
تبدیل متن به صدا	Qwen3-TTS، Chatterbox؛ سرویس ابری برای مقایسه.	مجوز تجاری و کیفیت فارسی را با گوش بسنجید (MOS داخلی).
دسته‌بندی ساده (قصد، احساس، موضوع)	مدل کوچک ۱ تا ۴B یا تنظیم دقیق روی داده خودتان.	ارزان‌ترین و سریع‌ترین؛ داده برچسب‌خورده بسازید.
خواندن اسکن فرم و فاکتور	Qwen-VL یا مدل بسته چندوجهی.	روی نمونه واقعی با کیفیت بد بسنجید.
نمونه‌سازی سریع	مدل بسته (Claude، GPT، Gemini).	سریع‌ترین راه برای دیدن «شدنی است یا نه»؛ بعد با مدل باز مقایسه کنید.
اجرای محلی روی لپ‌تاپ	Ollama یا LM Studio با Qwen/Gemma کوچک (۴ تا ۹B، GGUF ۴بیت).	برای آزمایش و یادگیری، نه تولید.

روش پیشنهادی برای انتخاب: ۱) فهرست کوتاه ۳ تا ۵ مدل از جدول‌ها و این فصل؛ ۲) مجوز و حافظه را بررسی کنید؛ ۳) هر کدام را روی ۵۰ تا ۲۰۰ نمونه فارسی خودتان بسنجید؛ ۴) فقط بعد از آن تصمیم بگیرید. فهرست «۱۰ دقیقه» در فصل روال هفتگی است.

کجا فهرست مدل‌های تازه را ببینیم

huggingface.co/models (Trending، فیلتر Languages: Persian)

artificialanalysis.ai (مقایسه کیفیت، سرعت، قیمت)

lmarena.ai (رأی کاربران)

openrouter.ai/models (فهرست و قیمت مدل‌های API)

ollama.com/library (مدل‌های قابل اجرای محلی)

Sebastian Raschka «Ahead of AI»، Interconnects، The Batch (خبرنامه)

بخش چهارم

عادت

از کجا بخوانیم، هر چند وقت و چطور یک مدل تازه را در ده دقیقه بسنجیم.

کجا به‌روز بمانیم

منبع زیاد است؛ مشکل انتخاب است. هر دسته را با هدفش آورده‌ایم. با ستاره‌دارها شروع کنید.

جدول‌ها و داده مستقل

منبع	به چه درد می‌خورد	هر چند وقت
★ **Artificial Analysis** artificialanalysis.ai	مقایسه مستقل کیفیت، سرعت (tok/s، TTFT) و قیمت مدل‌ها و سرویس‌دهنده‌ها؛ صوت هم دارد.	هفتگی
★ **LMArena** lmarena.ai	رأی کاربران؛ بخش‌های جدا برای متن، کد، تصویر، جست‌وجو.	هفتگی
Epoch AI epoch.ai	روندهای بلندمدت: هزینه آموزش، توان محاسبه، پیشرفت بنچمارک‌ها.	ماهانه
Hugging Face Leaderboards huggingface.co/spaces → leaderboard	جدول‌های تخصصی (صوت، فارسی، بردار معنایی). Open LLM Leaderboard قدیمی در ۲۰۲۵ بازنشسته شد و فقط بایگانی‌اش مانده.	ماهانه

مقاله‌ها

منبع	به چه درد می‌خورد	هر چند وقت
★ **HF Daily Papers** huggingface.co/papers	مقاله‌های داغ روز با پیوند به مدل و کد.	روزانه (فقط عنوان)
arXiv arxiv.org — cs.CL، cs.SD، eess.AS	منبع اصلی همه مقاله‌ها. cs.CL زبان، cs.SD و eess.AS صدا.	وقت نیاز
alphaXiv alphaxiv.org	بحث و پرسش روی هر مقاله؛ فهمش آسان‌تر می‌شود.	وقت نیاز

چطور یک مقاله را در ۲۰ دقیقه بخوانید: (۱) چکیده؛ (۲) شکل اول و جدول نتایج اصلی؛ (۳) نتیجه‌گیری و محدودیت‌ها؛ (۴) فقط اگر به کارتان می‌آید، بخش روش. بپرسید: با چه چیزی مقایسه کرده؟ کد و وزن منتشر شده؟ به فارسی یا صدای تلفنی ربط دارد؟

خبرنامه و وبلاگ

منبع	به چه درد می‌خورد
★ **The Batch** (DeepLearning.AI)	خلاصه هفتگی ساده و کم‌حاشیه؛ برای شروع عالی.
★ **Simon Willison's Weblog** simonwillison.net	آزمون عملی و صادقانه مدل‌ها و ابزارها، تقریباً هر روز.
Import AI (Jack Clark)	مقاله‌های مهم هفته با نگاه سیاستی و ایمنی.
Interconnects (Nathan Lambert)	عمیق درباره آموزش پس از پیش‌آموزش (RLHF، مدل‌های باز).
Latent Space (پادکست و خبرنامه)	نگاه مهندس هوش مصنوعی: عامل‌ها، ابزار، استنتاج. قسمت‌های صوتی هم دارد.
وبلاگ آزمایشگاه‌ها	Anthropic، OpenAI، Google DeepMind، Meta AI، Mistral، Qwen، DeepSeek — اعلام رسمی مدل‌ها. همیشه با منبع مستقل مقایسه کنید.
وبلاگ Hugging Face huggingface.co/blog	آموزش‌های عملی و معرفی مدل‌های باز، از جمله صوت.

دوره‌ها (رایگان)

دوره	برای چه
★ **Hugging Face LLM Course** huggingface.co/learn	ترنسفورمر، توکن‌ساز، تنظیم دقیق با کد واقعی.
★ **Hugging Face Audio Course**	ASR، TTS، طبقه‌بندی صدا؛ مستقیم مربوط به Phoenix.
Hugging Face Agents Course	عامل‌ها و استفاده از ابزار.
Andrej Karpathy — Neural Networks: Zero to Hero (یوتیوب)	ساختن یک مدل زبانی کوچک از صفر؛ بهترین راه برای فهم عمیق. ویدیوی «Intro to LLMs» او برای شروع یک‌ساعته عالی است.
fast.ai — Practical Deep Learning	یادگیری عمیق کاربردی، اول عمل بعد نظریه.
Stanford CS336 — Language Modeling from Scratch	برای وقتی که پایه محکم شد؛ جزئیات آموزش و استنتاج.

منابع فارسی و جامعه ایرانی

- صفحه سازمان‌های ایرانی در Hugging Face (مثل PartAI، MCINext) — مدل‌ها، داده‌ها و جدول‌های فارسی.

- فیلتر Languages: Persian در بخش Models و Datasets، مرتب‌شده با Trending.
- داده Common Voice فارسی (Mozilla) — مرجع رایج برای سنجش گفتار به متن فارسی.

روال هفتگی

بازه	چه کنید	زمان
روزانه	عنوان‌های HF Daily Papers و Trending مدل‌ها؛ یک خبرنامه. فقط آنچه به صوت، فارسی یا عامل‌ها مربوط است را یادداشت کنید.	۱۵ دقیقه
هفتگی	نگاه به Artificial Analysis و LMArena؛ خواندن کامل یک مقاله یا یک پست عمیق؛ امتحان یک مدل تازه در Space یا روی لپ‌تاپ. یک یادداشت سه‌خطی در کانال تیم.	۲ ساعت
ماهانه	یک موضوع عمیق (مثلاً «مدل‌های گفتار به گفتار») و یک آزمایش روی داده خودمان. بازبینی: آیا چیزی دیدیم که نقشه راه Phoenix را تغییر دهد؟	نیم روز

سنجش یک مدل تازه در ۱۰ دقیقه

۱. **چه کسی ساخته و با چه مجوزی؟** اگر تجاری نیست، همین‌جا تمام.

۲. **اندازه و حافظه:** با قاعده «پارامتر × بیت ÷ ۸» — روی سرور ما جا می‌شود؟

۳. **فارسی:** در کارت آمده؟ در جدول فارسی هست؟

۴. **عدد مستقل:** در Artificial Analysis یا آرنا چه جایگاهی دارد؟ نه فقط کارت سازنده.

۵. **آزمون دستی:** ۵ جمله واقعی از کار Phoenix (یک سؤال منابع انسانی، یک جمله محاوره‌ای، یک عدد و تاریخ) در نسخه نمایشی.

۶. **سرعت:** TTFT و tok/s (یا برای صوت: RTFx و تأخیر جریانی).

۷. **نتیجه:** «ارزش آزمون کامل دارد / ندارد» و یک دلیل.

اجرای خودتان

ابزار	کی
Spaces	سریع‌ترین راه؛ بدون نصب.
Ollama یا **llama.cpp**	اجرای مدل GGUF روی لپ‌تاپ: ollama run <model>
transformers (پایتون)	کنترل کامل؛ برای ارزیابی روی داده خودمان. برای صدا: pipeline("automatic-speech-recognition")
vLLM	اجرای جدی روی سرور با کارت گرافیک؛ همان چیزی که در تولید استفاده می‌شود.
lighteval / **lm-evaluation-harness**	اجرای بنچمارک‌های استاندارد برای تکرار یک عدد.

فهرست «به یک عدد اعتماد نکن»:

- تنظیم آزمون (چند مثال، با فکر یا بی‌فکر) یکسان است؟
- بازه اطمینان یا تعداد سؤال گفته شده؟
- چه کسی اندازه گرفته؟
- بنچمارک اشباع یا آلوده نیست؟
- به زبان و نوع داده ما (فارسی، تلفنی، محاوره‌ای) ربط دارد؟

تمرین‌ها

۱. **خواندن سه کارت مدل.** یک مدل زبانی، یک مدل گفتار به متن و یک مدل بردار معنایی که فارسی پشتیبانی می‌کنند پیدا کنید. برای هر کدام این جدول را پر کنید: سازنده · مجوز · پارامتر (کل/فعال) · دقت و قالب · پنجره متن · فارسی؟ · عدد مستقل · حافظه لازم · نتیجه.

۲. **خواندن یک جدول.** در LMArena دو مدل نزدیک به هم را پیدا کنید. آیا بازه اطمینانشان هم‌پوشانی دارد؟ با «کنترل سبک» جایشان عوض می‌شود؟

۳. **WER روی صدای خودمان.** ۲۰ قطعه صدای تلفنی فارسی (با اجازه و بدون اطلاعات شخصی) با متن درست آماده کنید. دو مدل گفتار به متن را اجرا کنید، متن‌ها را یکسان‌سازی کنید و WER و CER را با کتابخانه jiwer یا evaluate حساب کنید. عدد را با جدول فارسی مقایسه کنید: چقدر فرق دارد و چرا؟

۴. **تأخیر کل.** در یک تماس آزمایشی Phoenix، چهار زمان را جدا بنویسید: پایان نوبت، TTFT، ASR، مدل زبانی، TTFA. کدام بیشترین سهم را دارد؟

۵. **گزارش یک‌صفحه‌ای.** یک مدل تازه را با فهرست «۱۰ دقیقه» بسنجید و نتیجه را برای تیم بنویسید.

منابع

Hugging Face Hub docs, model cards: huggingface.co/docs/hub/model-cards

Open LLM Leaderboard archive: huggingface.co/docs/leaderboards/en/open_llm_leaderboard/archive

Open ASR Leaderboard paper: arxiv.org/abs/2510.06961

TTS Arena V2: huggingface.co/spaces/TTS-AGI/TTS-Arena-V2

Artificial Analysis: artificialanalysis.ai (text, speech-to-text, text-to-speech, speech-to-speech)

LMArena: lmarena.ai

Open Persian LLM Leaderboard: huggingface.co/spaces/PartAI/open-persian-llm-leaderboard

Persian LLM Alignment Leaderboard: mcilab-llm-alignment-evaluation.hf.space

Open Persian ASR Leaderboard: navidved-open-persian-asr-leaderboard.hf.space

Spontaneous Persian Speech dataset (SIGUL 2026): aclanthology.org/2026.sigul-1.26